



Rapport de projet NoSQL

Partie II - Évaluation et Analyse des Performances

El Houiti Chakib
Kezzoul Massili

23 décembre 2021

Introduction

Ce rapport fait suite à sa première partie qui concerne l'implémentation d'un moteur de requête *SPARQL* en étoiles en utilisant l'approche *hexastore*. Dans cette partie, nous allons analyser les performances de notre implémentation par rapport à d'autres implémentations. Notamment celle de Jena.

Dans un premier temps, nous allons préparer et analyser des bancs d'essais en utilisant *WatDiv*¹. *WatDiv* est système développé afin de mesurer les performances d'un moteur de requête *SPARQL*. Il consiste en la génération de jeux de données ainsi que des jeux de requêtes.

Dans un second temps, nous allons définir et comparer plusieurs plans de tests afin d'en trouver un (ou plusieurs) qui donne des résultats correctes, significatifs et interprétables.

Enfin, viendra la partie concrète d'évaluation des performances. On exécutera les plans de tests précédemment réalisés. Suivant les résultats obtenus, nous les présenterons selon des représentations graphiques que nous allons analyser. Nous expliquerons aussi les raisons à la base de ces résultats.

1 Bancs d'essais

1.1 Préparation des bancs d'essais

La première partie est de générer les jeux de données sur lesquelles les tests vont être exécutés. Pour cela, on utilise le programme *WatDiv*.

1.1.1 Génération des données

La génération d'un *dataset* se fait en utilisant la commande suivante :

```
0 ./watdiv -d <model-file> <scale-factor>
```

Listing 1 – Commande pour la création d'un dataset

- *model-file* est la template sur laquelle le programme se base pour créer le jeu de données ;
- Pour un *scaleFactor* = 1, on obtient environ 100K triplets. On peut donc augmenter le nombre de triplets en augmentant la valeur de *scaleFactor*.

Afin de répondre au besoin de l'évaluation, nous avons générer un *dataset* de 500K triplets ainsi qu'un autre de 1M de triplets.

1.1.2 Génération des requêtes

Afin de générer des requêtes, nous avons écrit un script *Shell* qui, à partir de quelques templates, génère pour chaque une d'elle un fichier contenant 1000 requêtes.

```
0 for template in ${TEMPLATE_DIR}/*.sparql-template;
1 do
2     template_name=${template##*/}
3     template_name=${template_name%.sparql-template}
4     query_file=${RESULT_DIR}/${template_name}.queryset
5
6     if [ $overwrite -eq 0 ] && [ -f $query_file ]; then
7         echo -e "File '$query_file' already exists.\nDo you want to overwrite ? (any
8         read $x
9         echo -e "Overwriting ..."
10        overwrite=1
```

1. Waterloo SPARQL Diversity Test Suite.

```

11  fi
12
13  $WATDIV/watdiv -q $WATDIV/model/wsdm-data-model.txt ${template} $NB_QUERIES 1 >
14  $querie_file
15  i=$((i+1))
done

```

Listing 2 – "Extrait du script qui génère les requêtes

1.2 Analyse des bancs d'essais

L'analyse des bancs d'essais se fait principalement sur la *qualité*² des requêtes générées.

1.2.1 Première version

Une première version du banc a été réalisée en utilisant les templates fournies de base. Quelques statistiques ont été extraites de ces templates afin de visualiser la *qualité* de ses requêtes.




FIGURE 1 – Nombres de requêtes sans réponses et dupliquées

Sur la figure 1, on voit pour chaque template le nombre de requêtes sans réponses (en bleu) ainsi que le nombre de requêtes en doubles (en orange). Le nom des templates commence par Q_i , où i représente le nombre de *patterns* des requêtes associées.

On observe clairement sur l'histogramme que trois groupes de templates se forment.

- 1 pattern** Ces templates ont un grand nombre de requêtes dupliquées et peu de requêtes sans résultats. Cela est probablement dû au fait que plus la requête est simple (peu de pattern) et plus elle a de résultats. Par contre, cela diminue le nombre de requêtes *différentes* qu'on peut générer pour cette template.

2. On définit ici la *qualité* d'une requête par la qualité des analyses qui découleront de celles-ci

2 patterns On observe sur ce groupe que quasiment toutes ses requêtes sont uniques mais aussi qu'elles sont toutes sans résultats. Ce qui n'est pas souhaitable. Nous reviendrons plus tard sur ces templates afin de voir d'où viens ce problème.

3 patterns ou plus Ce groupe donne un résultat assez varié. On observe clairement ici une corrélation entre le nombre de doublons et le nombre de requêtes sans réponses. plus l'un est élevé et plus l'autre est faible.

Ces résultats ne sont pas satisfaisant car ils biaiseront fortement les résultats des performances. En effet, un nombre élevé de requêtes sans réponses affectera forcément le temps d'exécution de notre implémentation car celle-ci s'arrête dès qu'un des patterns ne donne pas de résultat. la requête ne s'exécute pas entièrement. Cette valeur doit donc être *minimal*.

Le nombre de doublons aussi doit être de préférence proche de zero. Dans le cas contraire une requête qui apparait trop souvent influencera plus que les autres la moyenne du temps d'exécution. Si par exemple, cette requête s'exécute plus rapidement alors la moyenne se verra sous-estimé. Par contre, ce facteur reste moins important que le nombre de requête sans réponses. De plus, le nombre de doublons, i.e le nombre de requêtes qui se repète au moins une fois, n'est pas un nombre représentatif du problème des doublons. En effet, si par exemple, on a N doublons et que c'est une seule requête qui se repète N fois. Alors ce cas sera beaucoup plus problématique que le cas où on a $N/2$ requêtes qui se repètent 2 fois chaqu'une. Donc le nombre maximum de répétition d'une requête est un indicateur à privilégié au nombre de doublons.

1.2.2 Vers une amélioration du banc d'essai

Les requêtes à un seul pattern donnent un résultat satisfaisant. On a donc décider de les laisser tel quel. Par contre, les requêtes avec deux patterns ne le sont pas du tout. Pour remedier à cela nous avons changer les templates associées. On obtient à la fin la figure suivante :




FIGURE 2 – Nombres de requêtes sans réponses et dupliquées - amélioré

On voit ici que le nombre de requêtes sans réponses est assez faible. Par contre, le nombre de doublons

n'a pas changé. Ceci est dû à l'implémentation de *WatDiv* qui ne permet pas³ la génération de requêtes sans doublons.

Pour remédier à cela, nous avons calculé, comme précisé dans la section précédente, le nombre maximum de répétition d'une requête (Qu'on va noter M dans ce qui suit). Ce qui nous donne le graphe ci-dessous.




FIGURE 3 – Nombres maximum de répétition d'une requête par template

On observe ici que, pour les requêtes à un seul pattern, M n'excède pas 15. Ce qui est un bon résultat. Mais, pour ce qui est des requêtes à deux pattern et plus, on a un M qui tourne autour des 100. Donc une requête qui se répète 100 fois influencera forcément la partie d'évaluation des performances.

En changeant les templates on n'a pas réussi à minimiser les deux valeurs de façon satisfaisante. Le meilleur résultat qu'on a pu avoir est le suivant :




FIGURE 4 – Nombres maximum de répétition d'une requête par template - amélioré

3. En tout cas, pas à notre connaissance

On a réussi à trouver des templates à deux patterns avec un résultat satisfaisant, mais pour ce qui est des requêtes à 3 patterns il est beaucoup plus compliqué d'en trouver. Si une template donne peu de duplications alors elle est donnera forcément plus requêtes sans réponses. On a donc décider de privilégier cette dernière.

2 Plan des tests

3 Évaluation des performances

Cette partie est en cours de réalisation.

4 Conclusion

4.1 Apport des évaluations

4.2 Perspectives d'amélioration